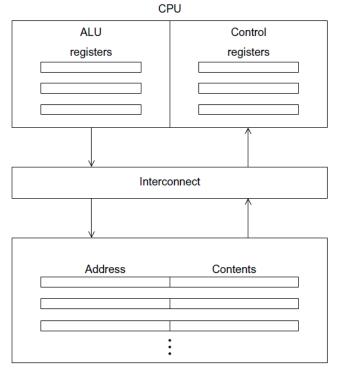
# CÓMPUTO PARALELO (INTRODUCCIÓN)

Francisco J. Hernández López fcoj23@cimat.mx

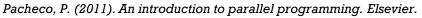


### ARQUITECTURA VON NEUMANN (1945)

- Básicamente, contiene:
  - Memoria principal
  - Unidad de Procesamiento Central (CPU)
  - Interconexión entre la memoria y la CPU









John Von Neumann

### MEMORIA RAM



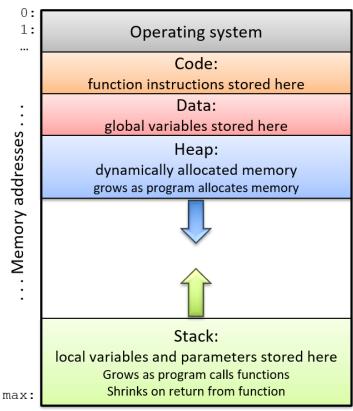
https://www.muycomputer.com/2018/11/04/memoria-ram-que-es-recomendaciones/

- Memoria principal o Random Access Memory (RAM)
  - DRAM: Dynamic RAM, son dispositivos basados en carga, en donde cada bit está representado por una carga eléctrica almacenada en un condensador (capacitor) muy pequeño. Dicha carga puede perderse en poco tiempo, por lo que es necesario que el sistema se actualice continuamente para evitar perder los datos. Ofrece: menor costo, menos espacio en la placa madre, menos energía y menos calor
  - SRAM: Static RAM, están basados en compuertas, cada bit se almacena en cuatro a seis transistores conectados. Retienen los datos mientras tengan energía, sin necesidad de ningún tipo de actualización de datos. Mayor costo, espacio en la placa madre, energía y calor

### PARTES DE LA MEMORIA

- Pila (stack): Para variables locales. La pila aumenta en la llamada al procedimiento y disminuye en el retorno. Son escalares en lugar de arreglos o matrices
- Datos globales: Para objetos declarados estáticamente como varibles globales o constantes. Pueden ser arreglos u otras estructuras de datos
- Motículo (heap): Para objetos dinámicos. Se acceden mediante apuntadores y típicamente no son escalares

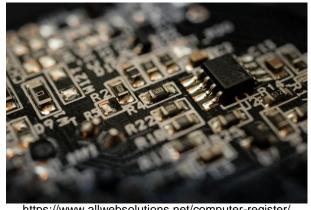
#### Parts of Program Memory



https://diveintosystems.org/book/C2-C\_depth/scope\_memory.html

John L. Hennessy and David A. Patterson. 2017. Computer Architecture, Sixth Edition: A Quantitative Approach (6th. ed.). Morgan Kaufmann Publishers Inc., San Francisco, CA, USA.

### REGISTROS



https://www.allwebsolutions.net/computer-register/

- Son un conjunto de espacios de almacenamiento temporal que se encuentran en el procesador, ocupando la capa superior de la jerarquía de la memoria
- Son lo que el procesador opera, por ej., en una operación como:

$$y = m * x + b$$

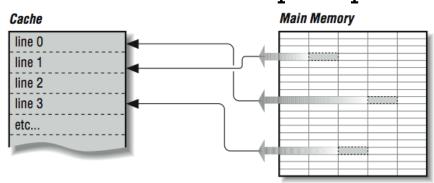
- m, x y b se almacenan en registros
- se realiza la multiplicación m \* x y el resultado se almacena en otro registro
- luego, se realiza la suma m \* x + b y el resultado se almacena en otro registro
- finalmente, el resultado va del registro a la posición de memoria y

### CACHÉ



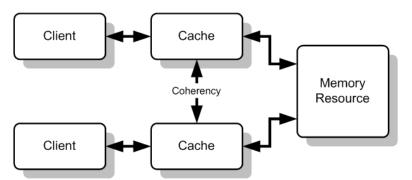
https://www.techyv.com/article/cache-memory-types-and-importance/

- Entre los registros y la memoria principal hay varios niveles de memoria caché que tienen menor latencia y mayor ancho de banda que la memoria principal y en donde los datos se conservan durante un periodo de tiempo intermedio
- Si un elemento de los datos se reutiliza poco después de que se necesitó por primera vez, este seguirá estando en la caché y por lo tanto se podrá acceder a él mucho más rápido que si se tuviera que traer desde la memoria principal



### COHERENCIA ENTRE LOS CACHÉS

- En multiprocesadores, las variables que se modifican deben devolverse a la memoria principal para que el resto de los procesadores puedan obtener el valor correcto de cada una de ellas
- Los procesadores deben ser conscientes de la actividad de la caché local. Quizá deban invalidar las líneas antiguas que contienen el valor anterior de la variable modificada para no utilizar datos obsoletos



Protocolos de coherencia:

- MSI (Modified-Shared-Invalid)
- MESI (M-Exclusive-S-I)
- MOSI (M-Owned-S-I)
- MOESI

https://es.wikipedia.org/wiki/Coherencia\_de\_caché

Charles Severance and Kevin Dowd. High Performance Computing. Rice University, Houston, Texas. 2012. *Available online:* http://cnx.org/content/col11136/1.5/

Cómputo Paralelo, Francisco J. Hernández-López

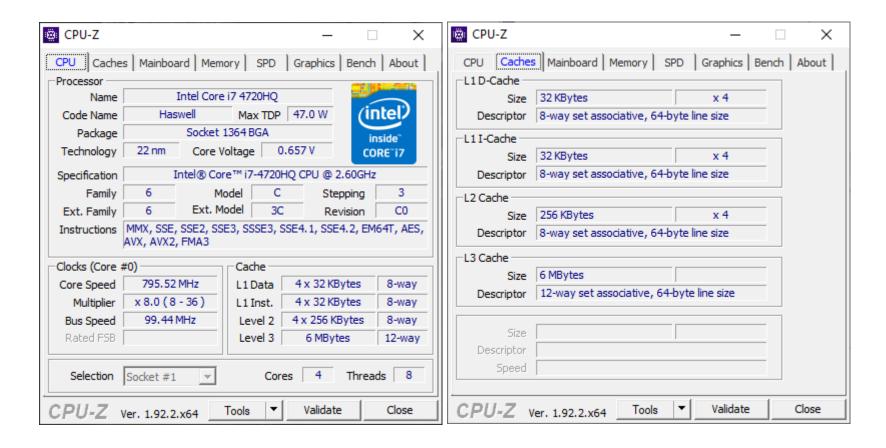
Ago-Dic 2023

Memory	Size	Latency	Bandwidth
L1 cache	32 KB	1 nanosecond	1 TB/second
L2 cache	256 KB	4 nanoseconds	1 TB/second Sometimes shared by two cores
L3 cache	8 MB or more	10x slower than L2	>400 GB/second
MCDRAM		2x slower than L3	400 GB/second
Main memory on DDR DIMMs	4 GB-1 TB	Similar to MCDRAM	100 GB/second
Main memory on Cornelis* Omni-Path Fabric	Limited only by cost	Depends on distance	Depends on distance and hardware
I/O devices on memory bus	6 TB	100x-1000x slower than memory	25 GB/second
I/O devices on PCIe bus	Limited only by cost	From less than milliseconds to minutes	GB-TB/hour Depends on distance and hardware

Datos aprox. para un sistema con un procesador Intel de 16 núcleos en el 2016.

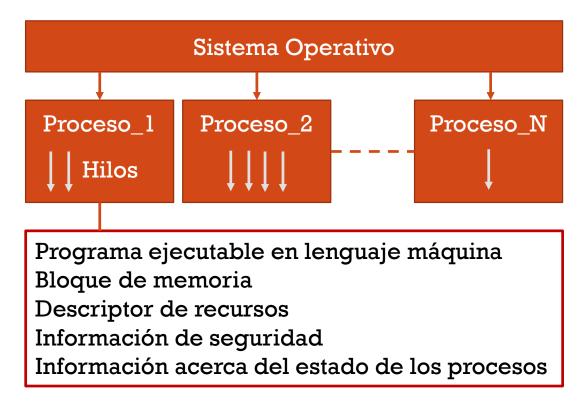
https://www.intel.com/content/www/us/en/developer/articles/technical/memory-performance-in-a-nutshell.html

### CPU-Z



### HILOS Y PROCESOS

- Proceso: Es un programa en ejecución (Proceso pesado)
- Hilo: Es una unidad básica que es parte de un proceso (Proceso ligero)



### LEY DE MOORE (GORDON E. MOORE, 1965)

 La cantidad de transistores en un chip se duplica aprox. cada dos años

Moore's Law: The number of transistors on microchips doubles every two years Our World in Data Moore's law describes the empirical regularity that the number of transistors on integrated circuits doubles approximately every two years This advancement is important for other aspects of technological progress in computing – such as processing speed or the price of computers. Transistor count 50,000,000,000 10.000.000.000 5.000.000.000 1,000,000,000 500,000,000 100.000.000 50.000.000 Pentium III Coppermine **ARM Cortex-A9** 10,000,000 5,000,000 1,000,000 500,000 100,000 50.000 Data source: Wikipedia (wikipedia.org/wiki/Transistor\_count) Year in which the microchip was first introduced OurWorldinData.org - Research and data to make progress against the world's largest problems. Licensed under CC-BY by the authors Hannah Ritchie and Max Roser.



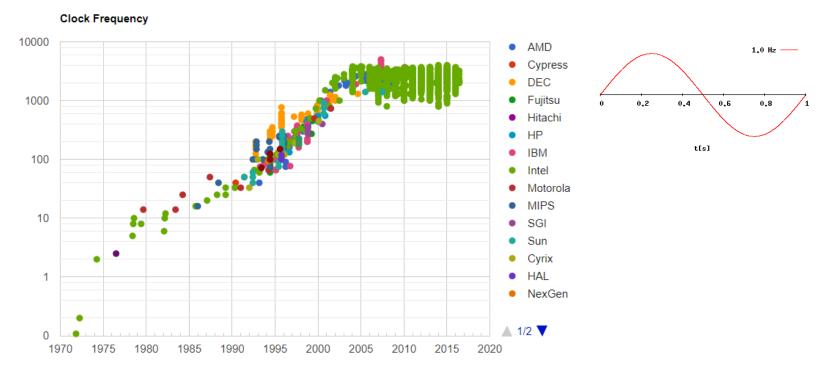
350 nm - 1993 250 nm - 1996 180 nm - 1999

130 nm - 2001

2 nm - > 2023

### VELOCIDAD DE RELOJ (CLOCK RATE)

 Cantidad de ciclos que ejecuta la CPU por segundo, medida en MHz o GHz



Clock Frequency (MHz)

### ¿QUÉ ES EL CÓMPUTO PARALELO (CP)?

 Ejecución de más de un cómputo (cálculo) al mismo tiempo o "en paralelo", utilizando más de un procesador.



Sistema de Cómputo Paralelo



Software

Parallel programming: For multicore and cluster systems. Rauber, Thomas, and Gudula Rünger. Springer Science & Business Media, 2013.

Cómputo Paralelo, Francisco J. Hernández-López

## MODELOS DE PROGRAMACIÓN EN PARALELO

#### Modelo máquina

- Es el nivel más bajo de abstracción.
- Consiste en una descripción de HW y el SO. Ejemplo: Los registros y la entrada/salida de los buffers.
- El lenguaje ensamblador esta basado en este nivel de modelos.

#### Modelo de arquitectura

- Interconexión de red de plataformas paralelas.
- Organización de la memoria
- Procesamiento síncrono o asíncrono.
- Modelo de ejecución SIMD (Simple Intruction Multiple Data) o MIMD (Multiple Instruction Multiple Data)

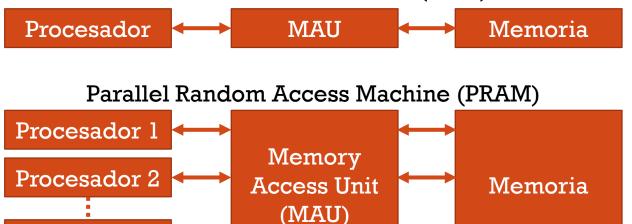
# MODELOS DE PROGRAMACIÓN EN PARALELO (C1)

Modelo computacional

Procesador n

- Provee un método analítico para diseñar y evaluar algoritmos
- La complejidad de un algoritmo se debe ver reflejado en el rendimiento de la computadora

Random Access Machine (RAM)



Parallel programming: For multicore and cluster systems. Rauber, Thomas, and Gudula Rünger. Springer Science & Business Media, 2013.

Cómputo Paralelo, Francisco J. Hernández-López

# MODELOS DE PROGRAMACIÓN EN PARALELO (C2)

- Modelo de programación
  - Describe un sistema de cómputo paralelo en términos de la semántica del lenguaje de programación o el ambiente de programación.
  - Especifica al programador como codificar un algoritmo paralelo.
  - Influenciado por: La arquitectura, el compilador, librerías, etc.
  - Criterios por los cuales pueden ser diferentes:
    - El nivel de paralelismo.
    - Especificaciones explicitas definidas por el usuario.
    - El modo de ejecución: SIMD, MIMD, Síncrono o Asíncrono.
    - Modos y patrones de comunicación para el intercambio de información.
    - Mecanismos de sincronización.

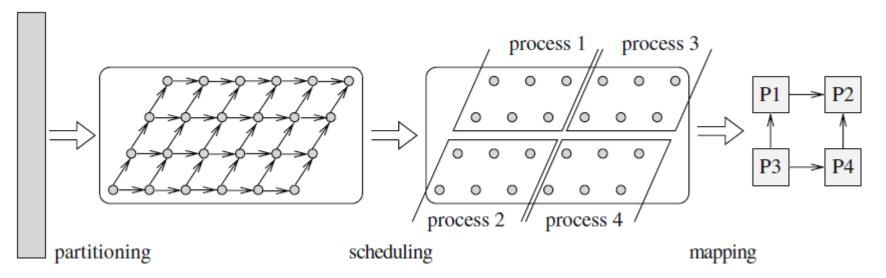
### PARALELIZACIÓN DE PROGRAMAS

- Se asume que el cómputo que se pretende paralelizar esta dado a partir de un algoritmo o programa secuencial.
- Se debe considerar el control y dependencia de los datos.
- Asegurar que el programa paralelo produce los mismos resultados que el programa secuencial.

Objetivo: Reducir el tiempo de ejecución de un programa tanto como sea posible, usando múltiples procesadores o cores.

### POSIBLES PASOS PARA LA PARALELIZACIÓN

- 1. Descomposición de los cálculos computacionales
- 2. Asignación de tareas a procesar o hilos
- 3. Mapeo de procesos o hilos a procesadores o cores físicos



Parallel programming: For multicore and cluster systems. Rauber, Thomas, and Gudula Rünger. Springer Science & Business Media, 2013.

Cómputo Paralelo, Francisco J. Hernández-López

# DESCOMPOSICIÓN DE LOS CÁLCULOS COMPUTACIONALES

- Aquí, los cálculos del algoritmo secuencial se descomponen en tareas y se determinan las dependencias entre la tareas.
- Dependiendo del modelo de la memoria, una tarea puede involucrar accesos a espacios de direcciones compartidas o puede ejecutar operaciones de paso de mensajes.
- Dependiendo de la aplicación, la descomposición de tareas se puede llevar a cabo:
  - En la fase de Inicialización 
     Descomposición Estática
  - Durante la ejecución del Programa 
     Descomposición Dinámica

Objetivo: Generar suficientes tareas para mantener a todos los cores ocupados todo el tiempo.

# ASIGNACIÓN DE TAREAS A PROCESAR O HILOS

- Un procesador o hilo:
  - Representa un flujo de control ejecutado por un procesador físico.
  - Puede ejecutar diferentes tareas, una por una.
- El número de hilos no necesariamente va ser el mismo que el número de cores físicos en un problema, aunque se suele utilizar de esta manera.
- La asignación de tareas a hilos también se le conoce como "Scheduling", puede haber planificación estática o dinámica.

Objetivo: Asignar las tareas tal que se obtenga un buen "Balance de Carga".

### MAPEO DE HILOS A CORES FÍSICOS

- El caso más simple es cuando cada proceso o hilo es mapeado a un solo core.
- Si ∃ menos cores que hilos, entonces múltiples hilos deben ser mapeados a un solo core. Este mapeo puede ser hecho por:
  - El Sistema Operativo (SO).
  - Soportado por sentencias del programa.

Objetivo: Tener a todos los cores trabajando, mientras que la comunicación entre ellos sea mínima.

### NIVELES DEL PARALELISMO

- A nivel de bits
- A nivel de instrucción
- A nivel de datos
- A nivel de tareas

#### 64bits







- Basado en incrementar el número de bits de una palabra (word length, word size o word width)
- Importante característica de los procesadores (8,16,32 o 64 bits)
- Ejemplo:
  - Tenemos un procesador de 16 bits y queremos sumar dos enteros (int) de 32 bits
  - Primero el procesador realiza la suma de los primeros 16 bits y después de los últimos 16 bits, completando la suma de los int en dos instrucciones
  - Un procesador mayor o igual a 32 bits realizaría la operación en una sola instrucción.

### A NIVEL DE INSTRUCCIÓN

- Capacidad de traslapar instrucciones
- Depende del pipeline del procesador

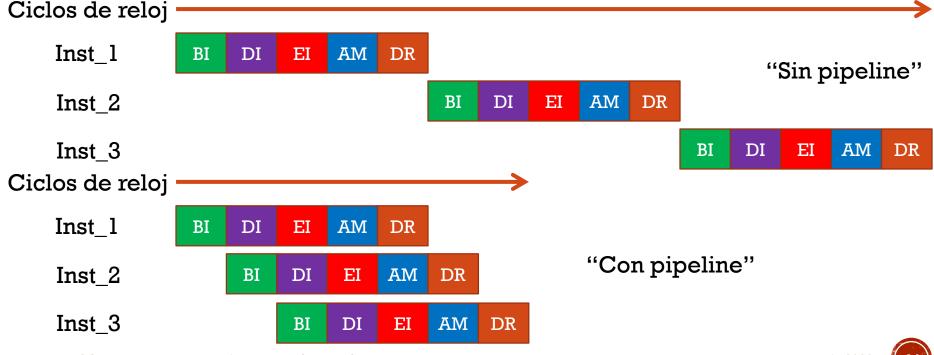
BI → Buscar Instrucción

DI → Descifrar Instrucción

EI → Ejecutar Instrucción

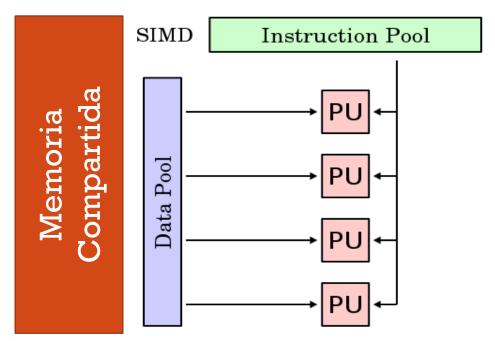
AM → Acceso a Memoria

DR → Dar Respuesta



### A NIVEL DE DATOS

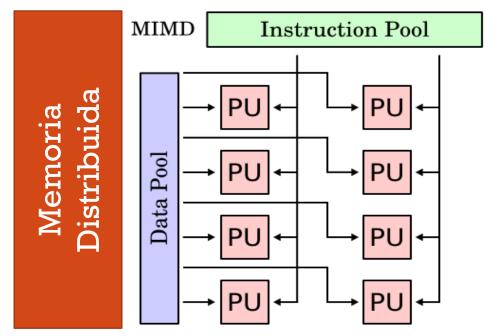
 Cada procesador realiza la misma tarea en diferentes partes de los datos (SIMD → Single Instruction Multiple Data)



SIMD [wikipedia], Taxonomía de Flynn

### A NIVEL DE TAREAS

 Diferentes procesadores pueden estar ejecutando diferentes instrucciones en diferentes partes de los datos (MIMD)



MIMD [wikipedia], Taxonomía de Flynn

### ARQUITECTURAS PARA EL CP







Computadora multi-core



Cluster



**GPUs** 



**FPGAs** 



Procesadores vectoriales



Xeon Phi Coprocessor

### LIBRERÍAS DE PROGRAMACIÓN PARA EL CP







**OpenMP**(Memoria
Compartida)



**OpenMPI** (Memoria Distribuida)



**CUDA** (Compute Unified Device Architecture) para GPUs.

**OpenCL** (**Open C**omputing **L**anguage) para GPUs y CPUs.

#### Mezcla de Arquitecturas:

Computadora (o múltiples cores) y un GPU (o un arreglo de GPUs).

Cluster con computadoras que contienen múltiples cores y a su vez cada maquina tiene un GPU (o un arreglo de GPUs). Así como mezclamos las arquitecturas también mezclamos las librerías:

- CUDA con (OpenMP, OpenMPI).
- OpenCL con (OpenMP, OpenMPI).

### GRACIAS POR SU ATENCIÓN

Francisco J. Hernández-López

fcoj23@cimat.mx

WebPage:

www.cimat.mx/~fcoj23

