OPENMP, PARTE 2

Francisco J. Hernández López

fcoj23@cimat.mx

SINCRONIZACIÓN

- Exclusión mutua
  - Utilizado para controlar el acceso a alguna variable compartida
  - La directiva **critical,** permite que un hilo a la vez tenga permitido ejecutar cierto código
- Sincronización de eventos
  - Para señalar un evento a través de los múltiples hilos
  - La directiva **barrier,** define un punto en el que cada hilo espera a que lleguen todos los demás
  - Una vez que llegan todos los hilos en ese punto, entonces todos pueden continuar su ejecución
  - Con esto se garantiza que todo el código anterior a la barrera lo han realizado todos los hilos

Chandra, R., Dagum, L., Kohr, D., Menon, R., Maydan, D., & McDonald, J. (2001). Parallel programming in OpenMP. Morgan kaufmann.

RESTRICCIONES EN LOS CICLOS

```
for (index = start ; index < end ; increment_expr)
```

- El comportamiento del ciclo debe ser calculable en tiempo de ejecución, según los parámetros: *start*, *end* y el *increment_expr*
- *start, end*: pueden ser alguna expresión numérica cuyo valor no cambia durante la ejecución del ciclo
- increment_expr: debe cambiar el valor de index la misma cantidad después de cada iteración

No están permitidos dentro del ciclo:
- *exit* o *goto* (Fortran)
- break o goto (C)

Operator	*Forms of* increment_expr
++	*index*++ or ++*index*
--	*index*-- or --*index*
+=	*index* += *incr*
-=	*index* -= *incr*
=	*index* = *index* + *incr* or *index* = incr + *index* or *index* = *index* - incr

Chandra, R., Dagum, L., Kohr, D., Menon, R., Maydan, D., & McDonald, J. (2001). Parallel programming in OpenMP. Morgan kaufmann.

CICLOS ANIDADOS

```
      subroutine sums(a, M, N)
      integer M, N, a(0:M, N), i, j

!$omp parallel do
      do j = 1, N
         a(0, j) = 0
         do i = 1, M
            a(0, j) = a(0, j) + a(i, j)
         enddo
      enddo
      end

      subroutine smooth(a, M, N)
      integer M, N, a(0:M + 1, 0:N), i, j

      do j = 1, N
!$omp parallel do
         do i = 1, M
            a(i, j) = (a(i - 1, j - 1) + a(i, j - 1) + &
                       a(i + 1, j - 1))/3.0
         enddo
      enddo
      end
```

Chandra, R., Dagum, L., Kohr, D., Menon, R., Maydan, D., & McDonald, J. (2001). Parallel programming in OpenMP. Morgan kaufmann.

UNIR CICLOS ANIDADOS

- OpenMP puede juntar multiples ciclos anidados en uno solo y entonces particionar el trabajo entre los hilos disponibles, usando la clausula: **collapse**

```
#pragma omp parallel for collapse(2)
  for (int i = 0; i < K; i++)
    for (int j = 0; j < M; j++)
      {
        C[i][j] = 0;
        for (int k = 0; k < L; k++)
          C[i][j] += A[i][k] * B[k][j];
      }
```

Barlas, Gerassimos. *Multicore and GPU Programming: An integrated approach*. Elsevier, 2014.

DIRECTIVA SECTIONS

- Especifica la ejecución en paralelo de algún bloque de código secuencial
- Pueden llamar diferentes funciones en paralelo

```
#pragma omp sections [clause[[,] clause]...] new-line
{
    [#pragma omp section ]
        structured block
    [#pragma omp section
        structured block ]
    ...
}
```

```
#pragma omp parallel
{
  #pragma omp sections
  {
    #pragma omp section
      func_a();
    #pragma omp section
      func_b();
  }
}
```

Van der Pas, R., Stotzer, E., & Terboven, C. (2017). *Using OpenMP—The Next Step: Affinity, Accelerators, Tasking, and SIMD*. MIT Press

PARALELISMO ANIDADO

- Podemos agregar una región paralela dentro de otra, habilitando el paralelismo anidado con:

  omp_set_nested(ban_nested);

- ban_nested=1, habilita el paralelismo anidado
- ban_nested=0, deshabilita el paralelismo anidado

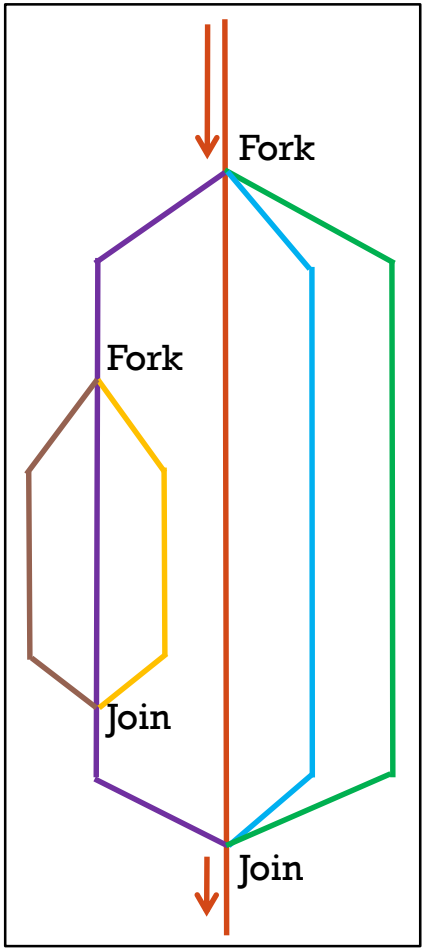

Multiplicación de Matrices

```
#pragma omp parallel private(row,col,i)
{
  #pragma omp for schedule(static)
  for (row = 0; row < size; row++) {
    #pragma omp parallel shared(MA, MB, MC, size)
    {
      #pragma omp for schedule(static)
      for (col = 0; col < size; col++) {
        MC[row][col] = 0.0;
        for (i = 0; i < size; i++)
          MC[row][col] += MA[row][i] * MB[i][col];
      }
    }
  }
}
```

RAUBER, T., & RÜNGER, G. Parallel programming: For multicore and cluster systems. Springer Science & Business Media, 2010.

ACCESO EFICIENTE A LA MEMORIA

- En C/C++, los arreglos están almacenados en la memoria por filas (row-major), mientras que en Fortran se almacenan por columnas (column-major)
- Cuando un elemento del arreglo se transfiere de la memoria RAM a la caché los vecinos de ese elemento (que están en la misma fila, C/C++) también se transfieren a la caché
- Por lo tanto, el orden en que accedemos a los datos en un programa, es de vital importancia para alcanzar un buen rendimiento

```
for (int j=0; j<n; j++)
   for (int i=0; i<n; i++)
      sum += a[i][j];
```

```
for (int i=0; i<n; i++)
   for (int j=0; j<n; j++)
      sum += a[i][j];
```

Chapman, B., Jost, G., & Van Der Pas, R. (2008). Using OpenMP: portable shared memory parallel programming (Vol. 10). MIT press.

MÉTRICAS (*SPEEDUP*)

- La mejora en el tiempo de ejecución se expresa típicamente como la aceleración o ganancia del rendimiento (*speedup*)

$$speedup = \frac{t_{seq}}{t_{par}}$$

donde t_{seq} y t_{par}, son los tiempos que puede tomar una computadora para realizar cierto procesamiento de forma secuencial y paralelo, respectivamente.

- Estos tiempos, podrían estar influenciados por:
  - Habilidad del programador
  - Elección del compilador
  - Habilitar banderas de compilación (-O2, -fast_math, …)
  - El Sistema Operativo
  - El tipo del sistema de archivos de los datos
  - La hora del día (Ej. cuando usamos un servidor compartido)

Barlas, Gerassimos. *Multicore and GPU Programming: An integrated approach*. Elsevier, 2014.

REGLAS PARA MEDIR LOS TIEMPOS

- El programa secuencial y paralelo deben probarse en plataformas de software y hardware idénticas y en condiciones similares
- El programa secuencial debe ser la solución más rápida del problema en cuestión

Barlas, Gerassimos. *Multicore and GPU Programming: An integrated approach*. Elsevier, 2014.

MÉTRICAS (EFICIENCIA)

- Formalmente definida como:

$$efficiency = \frac{speedup}{N} = \frac{t_{seq}}{N\ t_{par}}$$

donde N es el número de núcleos utilizados.

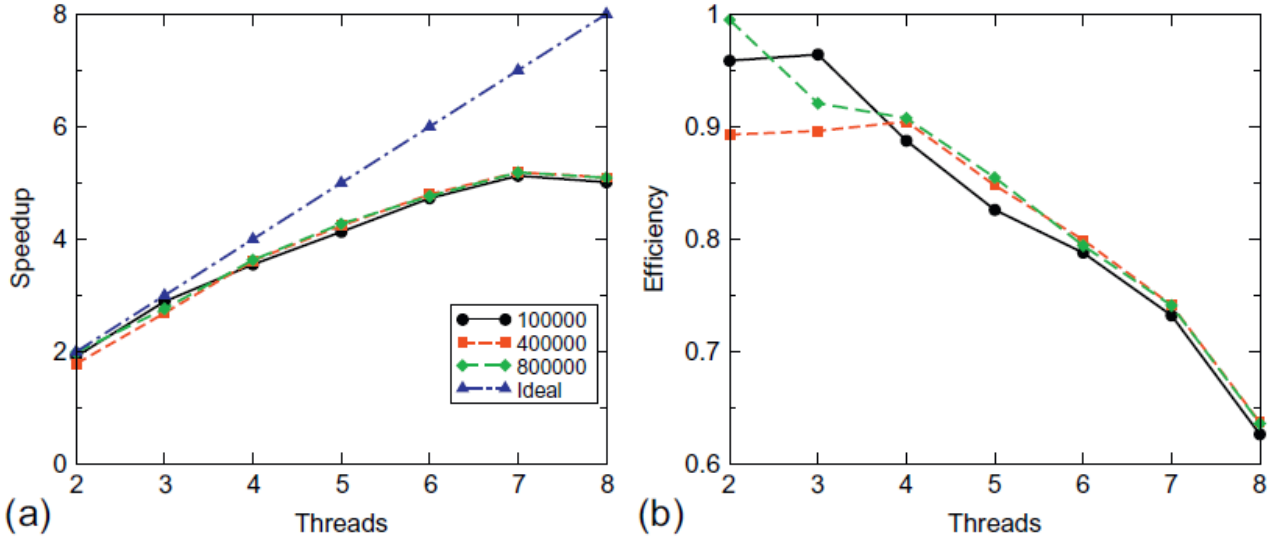

Curvas de *speedup* y eficiencia para un programa que calcula la integral definida de una función aplicando la regla del trapecio. Estos resultados reportados en [Barlas, Gerassimos], fueron obtenidos en una CPU i7 950 quad-core y promediando 10 ejecuciones.

Barlas, Gerassimos. *Multicore and GPU Programming: An integrated approach*. Elsevier, 2014.

LEY DE AMDAHL (1967)

$$speedup = \frac{t_{seq}}{t_{par}} = \frac{T}{(1-\alpha)T + \frac{\alpha T}{N}} = \frac{1}{1-\alpha+\frac{\alpha}{N}}$$

T tiempo secuencial

α parte del código que puede paralelizarse

$1-\alpha$ parte del código que tiene que ejecutarse de forma secuencial

N número de procesadores

- Ignorando los costos de particionamiento, comunicación y coordinación, Cuando $N \rightarrow \infty$, $speedup = \frac{1}{1-\alpha}$

Barlas, Gerassimos. *Multicore and GPU Programming: An integrated approach*. Elsevier, 2014.

LEY DE AMDAHL (SPEEDUP Y EFICIENCIA)

- Curvas de speedup y eficiencia para diferentes valores de α

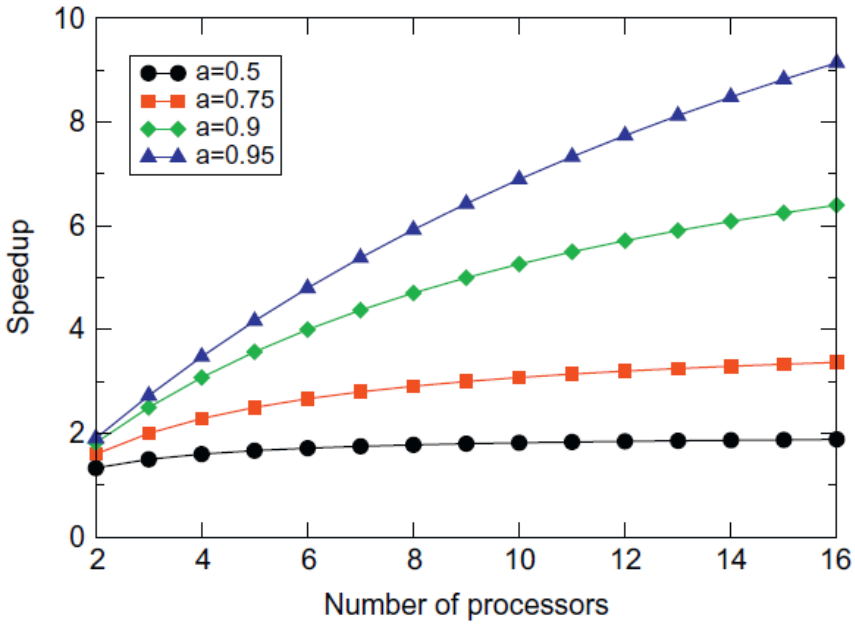

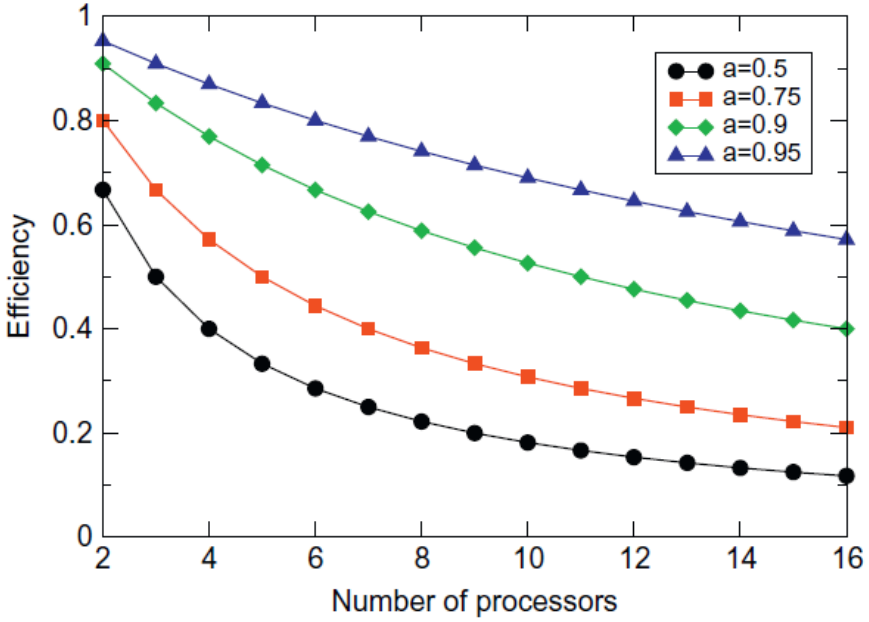

Barlas, Gerassimos. *Multicore and GPU Programming: An integrated approach*. Elsevier, 2014.

LEY DE GUSTAFSON-BARSIS (1988)

$$speedup = \frac{t_{seq}}{t_{par}} = \frac{(1-\alpha)T + N\alpha T}{T} = (1-\alpha) + N\alpha$$

T tiempo que requiere el programa en paralelo

α parte del código que puede paralelizarse

$1-\alpha$ parte del código que tiene que ejecutarse de forma secuencial

N número de procesadores

$$efficiency = \frac{1-\alpha}{N} + \alpha$$

- Ignorando los costos de particionamiento, comunicación y coordinación, Cuando $N \rightarrow \infty$, $efficiency = \alpha$

Barlas, Gerassimos. *Multicore and GPU Programming: An integrated approach*. Elsevier, 2014.

LEY DE GUSTAFSON-BARSIS

- Curvas de speedup y eficiencia para diferentes valores de α

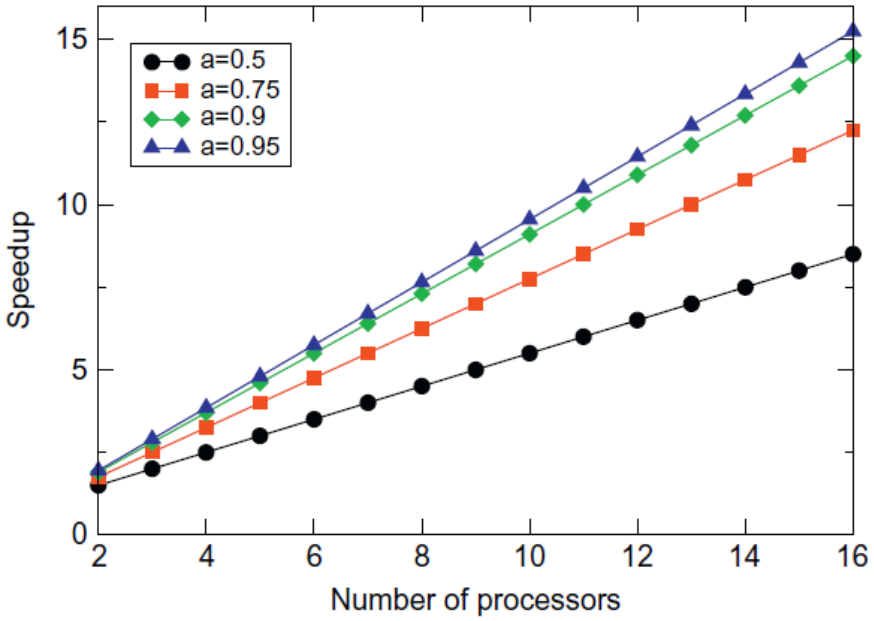

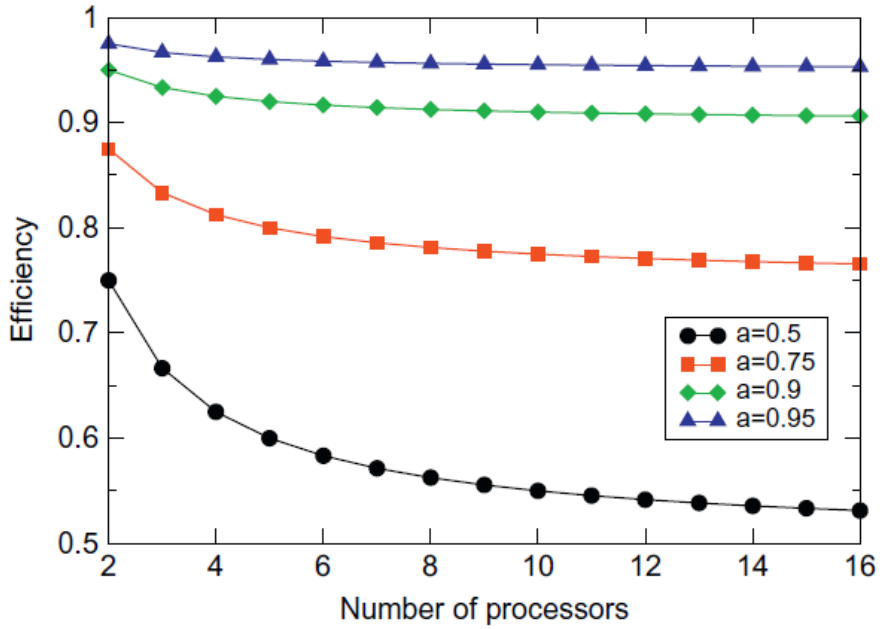

Barlas, Gerassimos. *Multicore and GPU Programming: An integrated approach*. Elsevier, 2014.

GRACIAS POR SU ATENCIÓN

Francisco J. Hernández-López

fcoj23@cimat.mx

WebPage:

www.cimat.mx/~fcoj23